




Trabalho de Séries Temporais

Henrique José Rosalino Victorio RA: 241016

Davi Jorge Negrete RA: 239466

Leonardo dos Santos RA: 239706

João Pedro Pires Martins Shayer RA: 185320



Série Temporal estudada

- ✦ Estudamos a quantidade mensal de ovos produzidas no Brasil;
- ✦ Como ajuste populacional, adicionamos a população anual em todos os meses no dataframe para considerar o crescimento da população;
- ✦ Dados foram pegos do Banco Central do Brasil, possuem 429 observações dos anos de 1989 até 2024
- ✦ A série temporal sob análise é composta por observações de periodicidade mensal.




Necessidade da previsão

- ✦ Ajustar oferta (produção, estoque) à demanda esperada
- ✦ Definir quando ampliar granjas ou reduzir custos
- ✦ Programar manutenção e investimentos
- ✦ Antecipar eventuais faltas ou excessos
- ✦ Entender sazonalidade e impactos de calendário




Série Temporal estudada

Gráfico da Série Temporal dos Ovos



Série Temporal estudada

```
pop_anual <- data.frame(  
  Data = paste0(1989:2024),  
  populacao = c(  
    147404000, 149650000, 152755000, 154725000, 156751000, 158851000, 161176000,  
    163491000, 165569000, 167664000, 169799000, 175786000, 177866000, 179914000,  
    181809000, 183627000, 185286000, 186770000, 188079000, 189335000, 190755000,  
    190755798, 192379287, 193946886, 195498211, 201032714, 202798685, 204450649,  
    206081432, 207660929, 210147125, 211755692, 213317639, 203062512, 204250000,  
    205680000  
  )  
)  
  
pop_anual <- pop_anual %>%  
  group_by(Data, populacao) %>%  
  summarize(Data = paste0(sprintf("%02d", 1:12), "/", first(Data)), .groups = "drop") %>%  
  unnest(cols = c(Data))  
  
ovo <- read_csv("ovo.csv")  
ovo <- left_join(ovo, pop_anual, by = "Data")  
ovo$y <- 12 * ovo$`Quantidade de ovos produzida - Duzias (mil)` / (ovo$populacao / 1e6)  
  
ovo <- ovo %>%  
  mutate(Data1 = parse_date_time(Data, orders = "my")) %>%  
  rename(ds = Data,  
         y = `y`)
```



Série Temporal estudada


```
ovo$ds <- as.Date(paste0("01/", ovo$ds), format = "%d/%m/%Y")

ovo <- ovo %>% arrange(ds)

ovo <- ovo %>%
  mutate(
    dias_no_mes = days_in_month(ds),
    y = y / dias_no_mes * 30
  ) %>%
  as_tsibble(index = ds)


ovo_mensal <- ovo %>%
  mutate(month = factor(month(ds, label = TRUE)))

media_mensal <- ovo %>%
  mutate(Month = month(ds, label = TRUE)) %>%
  group_by(Month) %>%
  summarise(Media_Ovos = mean(y),
            std = sd(y)) %>%
  ungroup()
```




Análise da Série

Produção de Ovos (Sem Tendência) - Densidade por Mês



Análise da Série

ACF (sem a tendência)



Modelos que podem funcionar

- ✦ **ETS:** Utiliza suavização exponencial para modelar automaticamente os componentes de erro, tendência e sazonalidade da série. Se adapta rapidamente a mudanças nos padrões temporais e consegue lidar com diferentes tipos de sazonalidade (aditiva ou multiplicativa), sendo robusto para diversas situações de previsão.
- ✦ **ARIMA:** Combina as vantagens dos componentes AR e MA, capturando tanto a dependência das observações passadas quanto a correlação dos erros anteriores. Esta combinação permite modelar séries que apresentam tanto persistência temporal nas observações quanto efeitos de choques que se propagam por alguns períodos, oferecendo maior flexibilidade para capturar diferentes padrões de dependência temporal em uma única estrutura de modelo.
- ✦ **STL:** Decompõe a série temporal em seus componentes de tendência, sazonalidade e ruído, permitindo identificar e modelar padrões complexos que se repetem ao longo do tempo. Ao separar esses elementos, consegue capturar tanto tendências não-lineares quanto padrões sazonais irregulares.

Validação Cruzada

- ✦ Janela expansiva com janela inicial de 20% (86)
- ✦ Horizonte de 12 meses

Modelo	MAE	RMSE	P-valor Ljung Box
ETS	252	359	0.0105
ARIMA(2,1,2)	262	351	< 2.2e-16

- ✦ Ajustado sem validação cruzada:



Modelo	MAE	RMSE	P-valor Ljung Box
STL	115	181	< 2.2e-16

Validação Cruzada



Modelo	MAE	RMSE	P-valor Ljung Box
Drift	277	376	< 2.2e-16
Snaive	473	608	< 2.2e-16
Holt Winters	287	395	0.0105
TSLM	1109	1445	< 2.2e-16
GRU	1698	1886	0.003
XGBoost	855	1056	< 2.2e-16

Modelo	MAE	RMSE	AIC	P-valor Ljung Box	Teste ARCH
MA(6)	289	385	5818	< 2.2e-16	-
AR(1)*	269	367	5841	< 2.2e-16	-
SARIMA(2,1,2)(0,1,1)[12]	281	367	4324	0.012	-
ARIMA(2,1,2)+GARCH(3,3)	258	349	121	0.5208	0.5402
MA(6)+ GARCH(1,3)	267	355	115	0.5861	0.3518

Diagnóstico dos Modelos





Diagnóstico dos Modelos



Conclusão

- ✦ Concluimos que o modelo $ARIMA(2,1,2) + GARCH(3,3)$ e o modelo ETS são os que melhores se ajustam e prevêm futuros valores da nossa série temporal, em comparação a outros modelos que esperávamos que se ajustassem bem, como STL.
- ✦ Essas previsões fornecem insights valiosos para o planejamento estratégico do setor, permitindo melhor gestão de recursos, antecipação de demandas sazonais e tomada de decisões mais informadas sobre investimentos e políticas de produção.
- ✦ A metodologia aplicada demonstra a importância da comparação entre diferentes abordagens de modelagem para identificar o método mais adequado às características específicas de cada série temporal.





Obrigado!